

Relatório Técnico: Pipeline Geoespacial Automatizado para Modelagem de Distribuição de Espécies (SDM) – Cultura da Canola

1. Introdução e Objetivo do Projeto

O presente relatório técnico descreve o desenvolvimento e a arquitetura de um mini-pipeline geoespacial *End-to-End*, projetado para automatizar a extração, o processamento e a padronização de variáveis ambientais e de satélite. O objetivo central da ferramenta é fornecer uma base sólida de preditores climáticos e físicos (como altitude, temperatura, precipitação e índices de vegetação) prontos para alimentar algoritmos de Modelagem de Distribuição de Espécies (SDM).

O foco deste estudo de caso é mapear as condições favoráveis para a cultura da Canola (*Brassica napus*), utilizando um conjunto de ocorrências na região centro-sul da América do Sul durante o período de safra (abril a setembro de 2025). O pipeline foi desenvolvido em Python de forma estritamente modular, separando as responsabilidades de extração de dados via APIs (STAC/CDS), processamento matricial, amostragem cruzada e validação em scripts independentes.

2. Arquitetura e Tomada de Decisão

2.1. O "Coração" do Pipeline e Reprodutibilidade

Para assegurar a flexibilidade do código, adotou-se a estratégia de centralização de parâmetros. Todas as regras de negócio geográficas e temporais — incluindo os limites da *Bounding Box* (BBOX), janelas de tempo, limite de cobertura de nuvens, sistema de coordenadas (CRS) e resolução espacial alvo — foram isoladas em um arquivo `config.yaml`. Esta decisão arquitetural previne o *hardcoding* e transforma o pipeline em uma ferramenta genérica, capaz de ser imediatamente reaproveitada para outras culturas agrícolas ou áreas do globo. Adicionalmente, optou-se por um `requirements.txt` flexível (sem fixar *minor versions*) para evitar conflitos de resolução de dependências (*dependency hell*) nos ambientes dos avaliadores.

Devido ao grande volume de dados geoespaciais (Big Data), os arquivos raster finais não foram incluídos no repositório. No entanto, o pipeline é totalmente reprodutível: ao executar o `run_pipeline.py`, todos os GeoTIFFs serão gerados localmente na pasta `outputs/rasters/` em poucos minutos.

2.2. Otimização de Memória via *Cloud Downscaling*

Um dos maiores desafios no processamento de dados raster em larga escala é o volume de alocação de RAM (risco de *Out-Of-Memory* - OOM). A extração nativa do Copernicus DEM para a BBOX do edital em sua resolução original de 30 metros resultaria em um arquivo superior a 11.5 GB. Para solucionar isso, implementou-se uma estratégia de *Cloud Downscaling*. Através da biblioteca `odc.stac`, o parâmetro de resolução alvo ($\$0.001^\circ$ / $\sim 100\text{m}$) foi enviado diretamente na

requisição API, forçando os servidores em nuvem a realizarem a reamostragem antes do download. Isso reduziu o tráfego de rede e o armazenamento local em mais de 90%.

2.3. Automação em Servidor (*Headless Rendering*)

Para garantir a total autonomia do orquestrador (`run_pipeline.py`) e a compatibilidade com ambientes *cloud* (onde não existe interface gráfica), a renderização dos mapas de auditoria visual foi configurada utilizando o *backend* `Agg` do Matplotlib. Esta abordagem de execução silenciosa previne o bloqueio da esteira de dados e elimina o risco de falhas críticas.

3. Metodologia de Processamento e Alinhamento Espacial

A consolidação do *stack* de preditores exigiu um rigoroso alinhamento espacial, garantindo a integridade matemática para a modelagem SDM.

3.1. Raster Gabarito e Correção Global de Coordenadas

A Altitude (Copernicus DEM) foi eleita como "Raster Molde" (*Master Template*). Todos os outros preditores foram forçados a herdar seu *Shape*, *Bounds* e Sistema de Referência de Coordenadas (EPSG:4326).

Durante a importação dos dados do ERA5-Land, aplicou-se uma transformação matricial de rotação de eixos $((\text{longitude} + 180) \% 360) - 180$ para converter a longitude de padrão contínuo (0° a 360°) para o sistema cartesiano centrado em Greenwich (-180° a 180°). A não observância deste detalhe geraria falsos nulos (*Ghost Maps*) na extração tabular por deslocamento transcontinental.

3.2. Reamostragem (*Resampling*): Contínuo vs. Categórico

Aplicou-se distinção algorítmica rigorosa durante o processo de *resampling*:

- **Variáveis Contínuas (Temperatura, Precipitação, Altitude e NDVI):** Utilizou-se a interpolação **Bilinear**, garantindo a suavidade dos gradientes climáticos e fisiológicos.
- **Variáveis Categóricas (Uso do Solo):** O raster espacializado da ESA WorldCover foi reprojeto exclusivamente através do algoritmo de **Vizinho Mais Próximo** (*Nearest Neighbor*). Esta decisão proíbe terminantemente a interpolação contínua, preservando a integridade discreta das classes de cobertura terrestre.

3.3. Engenharia de Variáveis e Proteção Matemática

- **Indicadores Sintéticos:** Devido à alta latência para o download de séries temporais diárias do ERA5, variáveis como 'Dias de Geadas' foram construídas como Indicadores Sintéticos de Probabilidade Climática, utilizando limiares térmicos sobre as médias mensais.
- **Blindagem do NDVI:** Na geração dos índices espectrais (NDVI), adotou-se uma janela temporal de 15 dias de agosto com processamento em lotes (*chunks*). Para evitar divisões por zero em áreas de reflectância nula (água/sombras), adicionou-se uma constante infinitesimal ao denominador ($\text{NDVI} = \frac{\text{NIR} - \text{Red}}{\text{NIR} + \text{Red} + 0.0001}$), garantindo a integridade matricial.

4. Integração e Geração do Dataset Final

O último estágio consistiu na integração espaço-tabular. Utilizando o pacote `rasterio.sample`, realizou-se a extração de dados pontuais (*Point Sampling*). O algoritmo iterou sobre as coordenadas (Latitude/Longitude) do inventário original de ocorrências, perfurando o *stack* de rasters alinhados.

Sanitização de NoData e Outliers Espaciais:

O dataset original apresentou ruídos severos de GPS (ocorrências em outros continentes). O algoritmo interceptou ativamente essas anomalias geográficas, convertendo marcações espaciais de vazio (ex: `-32768`) para nulos padrão da linguagem (NaN). O produto final é a tabela `metadata.csv`, contendo a fusão perfeitamente limpa entre o *label* da espécie e os preditores, pronta para algoritmos de IA.

5. Validação e Resultados Visuais

A auditoria do Módulo 04 confirmou estatisticamente e visualmente o alinhamento pixel-a-pixel. Todos os rasters gerados compartilham estritamente o CRS EPSG:4326 e as mesmas dimensões matriciais.




Figura 1: Mosaico NDVI renderizado atestando a cobertura total da área de interesse sem falhas matriciais.




Figura 2: Preditores climáticos reprojados demonstrando a suavidade do gradiente térmico via interpolação Bilinear.

6. Desafios Técnicos, Limitações e Trabalhos Futuros

Durante a execução do *pipeline*, desafios de *Big Data* espacial foram resolvidos através de mitigações de software:

- **Restrição de Escopo Geográfico (Bounding Box):** Devido aos limites físicos de memória RAM local e a bloqueios de tráfego por requisições massivas em APIs públicas (Timeouts no Planetary Computer), tornou-se inviável processar a BBOX integral do edital (região Sul/Sudeste) em uma única máquina local. Para viabilizar a execução *end-to-end* do pipeline demonstrativo, o escopo geográfico de processamento foi restrito a um polígono cirúrgico englobando o polo produtor de Passo Fundo - RS. A execução do código para a área original do edital requer, obrigatoriamente, a adoção de um *cluster* de Big Data em nuvem.
- **Tratamento de Anomalias de API (ZIP/NC):** A API do Copernicus apresentou oscilações, retornando pacotes ZIP nomeados como *.nc*. Implementou-se uma rotina nativa de verificação de cabeçalho e descompactação em diretório temporário, com *garbage collection* automático, garantindo a reprodutibilidade *end-to-end* sem intervenção humana.
- **Mitigação de Gargalos de Rede:** Requisições ópticas no Planetary Computer sofriam de *Timeout*. A solução adotada foi uma paginação agressiva filtrando programaticamente imagens com baixo *cloud_cover*.

Limitações e Trabalhos Futuros:

O pipeline priorizou a estabilidade e a reprodutibilidade em infraestruturas locais de hardware. Como trabalho futuro, recomenda-se a migração do processamento para um ambiente de nuvem distribuída (como AWS EC2 ou Databricks via Apache Spark). Com maior capacidade de processamento paralelo, a resolução alvo poderia ser reduzida nativamente para 10 metros, aproveitando o potencial máximo do satélite Sentinel-2, além da substituição dos proxies mensais pela ingestão integral de bases meteorológicas diárias.

Devido a restrições de memória RAM local, optou-se por calcular o NDVI a partir de uma janela de 15 dias em agosto (pico do ciclo da canola) em vez do período completo abril–setembro. Essa

aproximação é válida para identificar áreas com vegetação ativa no meio da safra, mas recomenda-se, em trabalhos futuros, o uso de séries temporais completas ou de produtos MODIS pré-agregados.